

Redes Neuronales

Perceptrón y Adeline

Facultad de Ingeniería. Universidad del Valle

Septiembre de 2018

Contenido

- 1 Perceptrón
- 2 Limitaciones del perceptrón
- 3 Adeline
- 4 Ejercicios

Contenido

1 Perceptrón

2 Limitaciones del perceptrón

3 Adeline

4 Ejercicios

Definición

- Fue introducido por Rosenblatt a finales de los años 50
- Se inspira en los procesos de aprendizaje de los animales (ejemplo la visión), en los cuales la información va atravesando diferentes capas de neuronas
- Es un modelo unidireccional, compuesto por dos capas de neuronas, una de entrada y otra de salida
- La operación de este tipo puede darse con n neuronas de entrada y m de salida

Perceptrón

Definición




Figura 1: Modelo de Perceptrón, tomado de <http://neuroph.sourceforge.net/tutorials/Perceptron.html>

Definición

- Las neuronas de entrada no realizan ningún computo
- Se consideran señales discretas 0 o 1
- La operación para n neuronas de entrada y m de salida puede considerarse así:

$$y_i = H\left(\sum_{j=1}^n w_{ij}x_j - \Theta_i\right), \forall i, 1 \leq i \leq m$$

Donde $H(x)$ es la función escalón.

Θ_i umbral

Perceptrón

Definición

- El Perceptrón permite clasificar dos conjuntos linealmente separables en un plano o hiperplano
- La respuesta de la neurona es 1 si pertenece a la clase o 0 si no pertenece






Figura 2: Conjunto linealmente separable, tomado de <https://en.wikipedia.org/>


AND

X_1	X_2	S
0	0	0
0	1	0
1	0	0
1	1	1



x_1	x_2	x_3	S
σ	σ	σ	σ
\vdots			0
\vdots			0
\vdots			\vdots
1	1	1	1





Ejemplo

- Sea una neurona tipo perceptron con entrada x_1 y x_2
- Entonces la operación se define como:

$$y = H(w_1x_1 + w_2x_2 - \Theta)$$

Perceptrón

Ejemplo




Figura 3: Regiones de decisión del plano, tomado de [Brio and Molina, 2005]

Perceptrón

Definición

Como se puede ver se divide el plano en dos regiones. Como se puede ver se requiere que el problema a solucionar tenga **solución lineal**




Figura 4: Casos de compuertas <https://en.wikipedia.org/>

Perceptrón

Algoritmo de aprendizaje













Estructura	Regiones de Decisión	Problema de la XOR	Clases con Regiones Mezcladas	Formas de Regiones más Generales
1 Capa 	Medio Plano Limitado por un Hiperplano			
2 Capas 	Regiones Cerradas o Convexas			
3 Capas 	Complejidad Arbitraria Limitada por el número de Neuronas			

Figura 5: Regiones de decisión perceptron [Lippmann, 1988]

Perceptrón


Algoritmo de aprendizaje

Vamos a trabajar el perceptrón de una capa

- Se basa en la corrección de errores
- Vamos a introducir una tasa de aprendizaje ϵ : Indica el ritmo de aprendizaje
- Dados unos patrones x^u , salidas obtenidas y^u y salidas deseadas t^u
- Los pesos iniciales son aleatorios entre -1 y 1. Se utiliza la función de activación signo y entradas $\{-1, 1\}$.
- Se examina cada patrón y aplicamos la relación de cambio:

$$\Delta w_{ij}^u(t) = \epsilon \cdot (t_i^u - y_i^u) x_j^u$$

A esto se le conoce como **regla del perceptrón**



Algoritmo de aprendizaje

Vamos a trabajar el perceptrón de una capa

- Se basa en la corrección de errores
- Vamos a introducir una tasa de aprendizaje ϵ : Indica el ritmo de aprendizaje
- Dados unos patrones x^u , salidas obtenidas y^u y salidas deseadas t^u

Perceptrón

Algoritmo de aprendizaje

Vamos a trabajar el perceptrón de una capa

- Los pesos iniciales son aleatorios entre -1 y 1. Se utiliza la función de activación signo y entradas $\{-1, 1\}$.
- Se examina cada patrón y aplicamos la relación de cambio:

$$\Delta w_{ij}^u(t) = \epsilon \cdot (t_i^u - y_i^u) x_j^u$$

A esto se le conoce como **regla del perceptrón**

Algoritmo de aprendizaje

La función signo (sgn) se define así:

$$\text{sgn}(n) = \begin{cases} 1 & \text{si } n > 0 \\ 0 & \text{si } n = 0 \\ -1 & \text{si } n < 0 \end{cases}$$

Perceptrón

Algoritmo de aprendizaje

Para comprender el Perceptrón se mostrará en una forma gráfica

$$y_i^u(t) = \text{sgn}\left(\sum_{j=1}^n w_{ij} x_j^u - \Theta_i\right) = \text{sgn}(\|w_i\| \cdot \|x^u\| \cos(\phi))$$

Perceptrón

Algoritmo de aprendizaje




Figura 6: Aplicación regla perceptron [Brio and Molina, 2005]

Perceptrón

Algoritmo de aprendizaje




Figura 7: Aplicación iterativa de las reglas de decision [Brio and Molina, 2005]

Perceptrón

Algoritmo de aprendizaje

La idea es etiquetar con -1 y 1 dos regiones en el espacio

- 1 Inicializar los pesos aleatoriamente entre [-1 y 1]
- 2 Para el estado t . Calcular:

$$y^u(k) = \text{sgn}\left(\sum_{j=1}^n (w_j(t)x_j)\right)$$

- 3 Corregir pesos sinápticos (Si $t_j^u \neq y_j^u$)

$$w_j(t+1) = w_j(t) + \epsilon[t_j^u - y_j^u]x_j^u, j = 1, 2, \dots, n$$

- 4 Para si no se han modificado los pesos en los últimos p patrones o se ha llegado a un número de iteraciones especificado.

Perceptrón

Algoritmo de aprendizaje

Miremos la compuerta AND




Figura 8: Perceptrón compuesta AND

Algoritmo de aprendizaje

Miremos la compuerta AND

Entrada	Salida $t^u(k)$
 (-1,-1)	-1
(-1,1)	-1
(1,-1)	-1
(1,1)	1

Cuadro 1: Función AND con lógica función signo

Perceptrón

Algoritmo de aprendizaje

- 1 Inicialización de pesos. Elegimos $\epsilon = 0,5$

$$w_1 = 0,4, w_2 = -0,2, \Theta = 0,6$$

Handwritten calculation: $-0.4 + 0.2 = -0.2$

- 2 Con $t = 1$, patrón $(-1, -1)$, $y^u = \text{sgn}(\underline{-0,8}) = \underline{-1}$. Esta bien ya que esperamos -1 . $p = 1$

- 3 Para $t = 1$, patrón $(-1, 1)$, $y^u = \text{sgn}(\underline{-1,2}) = \underline{-1}$. Esta bien. $p = 2$

Perceptrón

Algoritmo de aprendizaje

- 4 Para $t = 1$, patrón $(1, -1)$, $y^u = \text{sgn}(0) = 0$ Esta mal, ya que esperamos -1 . Actualizamos pesos

$$w_1(2) = w_1(1) + \epsilon [t^u(1) - y^u(1)] x_1 = 0,4 + 0,5[-1 - 0](1)$$

$$w_1(2) = -0,1$$

$$w_2(2) = -0,2 + 0,5[-1 - 0](-1) = 0,3$$

$$\Theta(2) = 0,6 + 0,5[-1 - 0](-1) = 1,1$$

- 5 Ya que actualizamos, ahora $t = 2$, y revisamos.

Algoritmo de aprendizaje

$$w_1 = -0,1, w_2 = 0,3, \Theta = 1,1$$

- 6 Para $t = 2$; patrón $(-1,-1)$, $y^u = \text{sgn}(-1,1) = -1$. Correcto
 $p = 1$
- 7 Para $t = 2$; patrón $(-1,1)$, $y^u = \text{sgn}(-0,7) = -1$. Correcto
 $p = 2$
- 8 Para $t = 2$; patrón $(1,-1)$, $y^u = \text{sgn}(-1,5) = -1$. Correcto
 $p = 3$

Perceptrón

Algoritmo de aprendizaje

$$w_1 = -0,1, w_2 = 0,3, \Theta = 1,1$$

9 Para $t = 2$; patrón $(1,1)$, $y^u = \text{sgn}(-0,9) = -1$. Incorrecto

$$w_1(3) = -0,1 + 0,5[1 - (-1)](1) = 0,9$$

$$w_2(3) = 0,3 + 0,5[1 - (-1)](1) = 0,7$$

$$\Theta(3) = 1,1 + 0,5[1 - (-1)](-1) = 0,1$$

10 Ya que actualizamos, ahora $t = 3$, y revisamos.

Algoritmo de aprendizaje

$$w_1 = 0,9, w_2 = 0,7, \Theta = 0,1$$

- 11 Para $t = 3$; patrón $(-1,-1)$, $y^u = \text{sgn}(-1,7) = -1$. Correcto
 $p = 1$
- 12 Para $t = 3$; patrón $(-1,1)$, $y^u = \text{sgn}(-0,3) = -1$. Correcto
 $p = 2$
- 13 Para $t = 3$; patrón $(1,-1)$, $y^u = \text{sgn}(0,1) = 1$. Incorrecto

Algoritmo de aprendizaje

$$w_1 = 0,9, w_2 = 0,7, \Theta = 0,1$$

14 Para $t = 3$; patrón $(1,-1)$, $y^u = \text{sgn}(0,1) = 1$. Incorrecto

$$w_1(4) = 0,9 + 0,5[-1 - 1](1) = -0,1$$

$$w_2(4) = 0,7 + 0,5[-1 - 1](-1) = 1,7$$

$$\Theta(4) = 0,1 + 0,5[-1 - 1](-1) = 1,1$$

15 Ya que actualizamos, ahora $t = 4$, y revisamos.

Algoritmo de aprendizaje

$$w_1 = -0,1, w_2 = 1,7, \Theta = 1,1$$

16 Para $t = 4$; patrón $(-1,-1)$, $y^u = \text{sgn}(-2,7) = -1$. Correcto
 $p = 1$

17 Para $t = 4$; patrón $(-1,1)$, $y^u = \text{sgn}(0,7) = -1$. Incorrecto

$$w_1(5) = -0,1 + 0,5[-1 - 1](-1) = 0,9$$

$$w_2(5) = 1,7 + 0,5[-1 - 1](1) = 0,7$$

$$\Theta(5) = 1,1 + 0,5[-1 - 1](-1) = 2,1$$

Ahora con $t = 5$



Algoritmo de aprendizaje

$$w_1 = 0,9, w_2 = 0,7, \Theta = 2,1$$

- 18** Para $t = 5$; patrón $(1,1)$, $y^u = \text{sgn}(-0,5) = -1$. Incorrecto, diferencia salidas 2.

$$w_1(6) = 0,9 + 0,5[2](1) = 1,9$$

$$w_2(6) = 0,7 + 0,5[2](1) = 1,7$$

$$\Theta(6) = 2,1 + 0,5[2](-1) = 1,1$$

Ahora con $t = 6$

Perceptrón

Algoritmo de aprendizaje

$$w_1 = 1,9, w_2 = 1,7, \Theta = 1,1$$

19 Para $t = 6$; patrón $(-1,-1)$, $y^u = \text{sgn}(-4,7) = -1$. Correcto
 $p = 1$

20 Para $t = 6$; patrón $(-1,1)$, $y^u = \text{sgn}(-1,3) = -1$. Correcto
 $p = 2$


21 Para $t = 6$; patrón $(1,-1)$, $y^u = \text{sgn}(-0,9) = -1$. Correcto
 $p = 3$

22 Para $t = 6$; patrón $(1,1)$, $y^u = \text{sgn}(2,5) = 1$. Correcto $p = 4$

Termina.

Perceptrón

$$\text{Sgn}(x) = \begin{cases} 1 & x > 0 \\ 0 & x = 0 \\ -1 & x < 0 \end{cases}$$



$$w(t+1) = w(t) + \epsilon (t - y) X$$

Ejercicio :

- 1 Aplica el algoritmo para la compuerta AND, con $w_1 = 0,7$, $w_2 = -1,8$, $\Theta = 1,4$, $\epsilon = 0,5$
- 2 Aplica el algoritmo para la compuerta OR, con $w_1 = 0,7$, $w_2 = -1,8$, $\Theta = 1,4$, $\epsilon = 0,5$

$$\begin{matrix} x_1 & x_2 & y \\ -1, & -1, & -1 \end{matrix}$$

$$P_1, \begin{matrix} x_1 & x_2 & y \\ -1 & -1 & -1 \end{matrix} \quad w_1 = 0.7 \quad w_2 = -1.8 \quad \Theta = 1.4$$

$$\text{Sgn}(-0.7 + 1.8 - 1.4) = -1 \quad \checkmark$$

$$P_2, \begin{matrix} -1 & 1 & -1 \end{matrix} \quad \text{Sgn}(-0.7 - 1.8 - 1.4) = -1 \quad \checkmark$$


$$P_3, \begin{matrix} 1 & -1 & -1 \end{matrix} \quad \text{Sgn}(0.7 + 1.8 - 1.4) = 1 \quad \times$$

$$w_1 = 0.7 + 0.5(-2)(1) = -0.3$$

$$w_2 = -1.8 + 0.5(-2)(-1) = -0.8$$

$$\Theta = 1.4 + 0.5(-2)(-1) = 2.4$$

$$P_4 \rightarrow w_1 = 0.7, \quad w_2 = 0.2 \quad \Theta = 1.4$$



X_1 X_2 S_1 S_2

-1 -1 -1 -1

-1 1 -1 1

1 -1 -1 1

1 1 1 1

Contenido

1 Perceptrón

2 Limitaciones del perceptrón

3 Adeline

4 Ejercicios

Limitaciones del perceptrón

Limitaciones


- 1 El perceptrón monocapa no puede trabajar con problemas que no sean linealmente separables
- 2 Para esto utilizamos el perceptrón multicapa, la cual cuenta con una capa de entrada, capas ocultas y una capa de salida

Limitaciones del perceptrón

Limitaciones

Para el caso de la función XOR, tenemos el siguiente problema:

Figura 9: Problema del perceptrón con compuerta XOR, tomado de [Eduardo and Jesus Alfonso, 2009]



Contenido

1 Perceptrón

2 Limitaciones del perceptrón

3 Adeline

4 Ejercicios

Definición

- Fue introducido por Widrow [Widrow and Hoff, 1988], [Widrow and Winter, 1988] entre 1959 y 1988.
- Es de respuesta lineal a diferencia del perceptrón
- Puede trabajar con entradas continuas
- Se incorpora un elemento adicional llamado **bias** u **umbral** Θ . La cual se suma a la entrada (usualmente es -1)
- Utiliza mínimos cuadrados para el cálculo del error.
- Se tiene una tasa de aprendizaje ϵ

Regla del gradiente descendiente

- Si las entradas tiene vectores de entrada ortogonales, se podrá llegar a asociaciones perfectas
- La salida de la neurona es $y = \sum_{j=1}^n x_j w_j + \Theta$. Ya que la función de activación es lineal
- El cambio se basa en el cálculo del gradiente descendiente para los patrones de entrada. En este caso el error cuadrático

$$Err = \frac{1}{2} \sum_{j=0}^n (t^u(j) - y^u(j))^2$$

Regla del gradiente descendiente

- Lo que se busca es modificar los valores de forma iterativa mediante la regla del descenso del gradiente:

$$\Delta_p w_j = -\epsilon \frac{\partial Err^P}{\partial w_j}$$

Regla del gradiente descendiente




Figura 10: Regla del gradiente descendiente, tomado de [Eduardo and Jesus Alfonso, 2009]

Regla del gradiente descendiente

- Tomando en cuenta que el error global cuadrático medio es:

$$E = \frac{1}{2} \sum_{u=1}^m (t^u - y^u)^2$$

- La regla del gradiente descendiente busca el mínimo global, aplicando la regla en un patrón p cualquiera de la siguiente forma:

$$\Delta w_j = -\epsilon \frac{\partial E^p}{\partial w_j}$$

Esta va en sentido contrario, ya que deseamos hacer la derivada del error igual a 0

Regla del gradiente descendiente

- Al aplicar la derivada obtenemos que:

$$\Delta w_j = \alpha(t^u - y^u) * x_j$$

Algoritmo de aprendizaje

- 1 Inicialice los pesos aleatorios
- 2 Para cada patrón, actualice los pesos a razón de:

$$w_i(t+1) = w_i(t) + \epsilon * \Delta w_i$$

- 3 Actualizamos los pesos y Θ
- 4 Puede detenerse cuando todos los patrones cumplen la salida deseada o bien se han cumplido cierto número de iteraciones.